



SAPIENZA
UNIVERSITÀ DI ROMA


Facoltà di Ingegneria dell'Informazione, Informatica e Statistica

**CORSO DI LAUREA MAGISTRALE IN INGEGNERIA DELLE
COMUNICAZIONI**

Esame di Deep Learning

Prof. Aurelio Uncini

Segmentazione d'Istanza di Immagini Satellitari tramite Architettura Mask2Former



Candidato:
Irene Lontano
Matricola: 2130227

Anno Accademico:
2025-2026

Abstract

Il progetto si focalizza sull'implementazione dell'architettura Mask2Former (un modello di deep learning basato su Transformer, dedicato alla mask classification e all'apprendimento competitivo tramite Object Queries) nell'ambito di processi di segmentazione d'istanza per immagini satellitari.

I suoi componenti chiave includono la mask attention, che estrae caratteristiche localizzate vincolando la cross-attention all'interno delle regioni di maschera predette. In particolare, Mask2Former stabilisce un nuovo standard per la segmentazione panottica, la segmentazione di istanze e la segmentazione semantica.

Il case study di riferimento è quello della mappatura urbana e del suolo del settore dell'osservazione della Terra (*Earth Observation*) e utilizza il dataset pubblico di Dubai, pienamente funzionale allo scopo.

Dopo una disamina della letteratura di riferimento sull'algoritmo, fondamentale e di rassegna, viene ampiamente illustrato l'approccio metodologico (Pixel Decoder e Transformer Decoder), per passare poi alla progettazione e alla implementazione di codifica in puro PyTorch, relativamente alla struttura del dataset, data preprocessing, gestione della Masked Attention, esecuzione della strategia di pixel-matching e analisi dei risultati e delle curve di loss.

Indice

1	Introduzione	4
1.1	Il Contesto della Segmentazione	4
1.2	Classificazione Tassonomica	4
1.3	Perché Mask2Former è lo Standard SOTA	5
2	Letteratura di Riferimento	6
2.1	I Lavori Fondamentali e la Linea Evolutiva	6
2.2	Rassegne e Sviluppi Correlati	6
2.3	Standardizzazione Applicativa	7
3	Case Study: Il Dataset	
	Dubai	8
3.1	Caratteristiche del Dataset	8
3.2	Tassonomia delle Classi	
	Semantiche	8
3.3	Sfide Ingegneristiche del Dominio	9
	3.3.1 Sbilanciamento delle Classi	9
	3.3.2 Risoluzione Spaziale e Micro-Oggetti	9
	3.3.3 Effetto dell'Illuminazione e Ombre	9
4	Metodologia e Architettura di Dettaglio	10
4.1	Pipeline Sequenziale e Flusso dei Dati	10
4.2	Formulazione della Masked Attention	10
4.3	Set Prediction e Bipartite	
	Matching Loss	11
4.4	Efficienza di Memoria tramite Point-Based Loss	11
5	Progettazione e Implementazione	
	Software	12
5.1	Pixel Decoder	12
	5.1.1 Rottura delle Dipendenze e Semplificazione	12
	5.1.2 Codice Sorgente in PyTorch Puro	12
5.2	Transformer Decoder	14
	5.2.1 Cross-Attention e Self-Attention	14

5.2.2	Implementazione dello Strato del Decoder	15
5.2.3	Architettura del Decoder Completo	15
5.2.4	Esecuzione del Test Unificato	16
5.3	Unificazione dell'Architettura Completa: ResNet	16
5.4	Pipeline di Caricamento Dati	17
5.5	Vincoli Geometrici e Validazione End-to-End	17
6	Criterio di Loss e Fase	
	di Addestramento	19
6.1	Il Concetto di Loss Function nel Telerilevamento	19
6.2	Formalizzazione Matematica della Loss Combinata	19
6.3	Algoritmo di Assegnazione Hard-Assignment tramite Argmax Spaziale	20
6.4	Analisi Quantitativa del Test della Loss Iniziale	21
6.5	Protocollo di Addestramento e Configurazione degli Iperparametri	21
6.6	Analisi della Dinamica di Convergenza e delle Curve di Loss	22
6.7	Analisi Pixel-Level tramite Matrice di Confusione	22
6.8	Ispezione Diagnostica Finale e Analisi Spettrale delle Query	23
7	Conclusioni e Sviluppi Futuri	24
	Bibliografia	25

1 Introduzione

Il moderno scenario del telerilevamento satellitare (*Earth Observation*) richiede algoritmi di computer vision sempre più sofisticati per l'estrazione automatica di informazioni geometriche e semantiche dal territorio. La mappatura di contesti urbani complessi presenta sfide notevoli dovute alla variabilità spettrale degli oggetti, all'occlusione causata dalle ombre e alla densità delle strutture antropiche alternata a elementi naturali.

1.1 Il Contesto della Segmentazione

Nel dominio applicativo della Computer Vision, il problema del raggruppamento semantico dei pixel rappresenta uno dei pilastri fondamentali e storicamente più complessi. A seconda della semantica specifica adottata per definire le relazioni spaziali e categoriali, la letteratura scientifica ha tradizionalmente frammentato questo dominio in tre macro-task distinti.

-Segmentazione Semantica: focalizzata sull'assegnazione di una classe categoriale continua a ogni singolo pixel dell'immagine (concetto di *"stuff"*, come terreno, cielo, vegetazione), senza distinguere le singole istanze.

-Segmentazione d'Istanza: orientata esclusivamente alla rilevazione e al tracciamento geometrico di oggetti discreti e numerabili (concetto di *"things"*, come automobili, pedoni o edifici), ignorando lo sfondo.

-Segmentazione Panottica: proposta con l'obiettivo di unificare i due paradigmi precedenti all'interno di una mappatura globale e coerente della scena.

Storicamente, questa tripartizione ha costretto i ricercatori a progettare architetture altamente specializzate e computazionalmente rigi-

de per ciascun compito. I modelli basati sulla classificazione densa per-pixel tramite reti completamente convoluzionali (FCN) hanno dominato l'ambito semantico, mentre le architetture basate sulla generazione di proposte e box di localizzazione (come Mask R-CNN) hanno monopolizzato il tracciamento delle istanze. Questa frammentazione metodologica ha comportato una massiccia duplicazione degli sforzi di ricerca e di ottimizzazione hardware.

L'obiettivo principale di questo lavoro è la progettazione, l'implementazione e l'addestramento di un sistema avanzato di segmentazione d'istanza basato sull'architettura *Mask2Former* in puro PyTorch.

1.2 Classificazione Tassonomica

Dal punto di vista tassonomico, Mask2Former si classifica come un modello appartenente alla famiglia dei **Mask Classification Transformer con Set Prediction End-to-End**.

Mentre i modelli tradizionali deducono la maschera finale calcolando un vettore di probabilità Softmax in modo indipendente su ogni pixel, Mask2Former opera una scomposizione del problema in due sotto-task paralleli coordinati da vettori globali chiamati *Object Queries*: la generazione di un insieme fissato N di maschere binarie globali e la classificazione probabilistica di ciascuna maschera intesa come entità geometrica unitaria. L'assegnazione delle predizioni ai target reali non avviene tramite l'allineamento denso dei pixel, ma viene formulata come un problema di **Bipartite Matching** (Set Prediction), eliminando la necessità di euristiche post-addestramento pesanti come la rimozione dei duplicati tramite *Non-Maximum Suppression* (NMS).

1.3 Perché Mask2Former è lo Standard SOTA

Mask2Former è diventato lo standard di riferimento assoluto (*State-of-the-Art* - SOTA) nella visione artificiale contemporanea per tre ragioni cruciali:

1. **Universalità Architetturale:** Dimostra che un singolo modello, preservando intatti l'architettura, le funzioni di loss e i parametri di addestramento, è in grado di eccellere in tutti e tre i compiti di segmentazione.
2. **Velocità di Convergenza:** Sostituendo la cross-attenzione standard con l'attenzione mascherata, accelera il training di oltre 6 volte rispetto a MaskFormer, riducendo le epoche necessarie alla focalizzazione del gradiente.
3. **Efficienza di Memoria:** Abbatte il consumo di memoria di ben 3 volte (da 18GB a soli 6GB per immagine) calcolando le loss di corrispondenza e di segmentazione su un subset ristretto di $K = 12544$ punti estratti tramite importanza e campionamento casuale.

Successivamente verrà riportata la struttura ed il funzionamento dell'argomento in maniera più approfondita.

2 Letteratura di Riferimento

La letteratura di riferimento riguardante l'architettura *Mask2Former* e il paradigma della *Mask Classification* si è sviluppata rapidamente negli ultimi anni, radicandosi sull'evoluzione dei meccanismi di attenzione applicati al processamento visivo. Di seguito ne è riportata una sintesi cronologica e metodologica, evidenziando i lavori fondamentali, le rassegne e gli sviluppi più recenti dello stato dell'arte.

2.1 I Lavori Fondamentali e la Linea Evolutiva

L'algoritmo si colloca al culmine di una transizione architetturale che ha scardinato i classici approcci convoluzionali basati su classificazione per singolo pixel. Gli articoli di riferimento che ne tracciano la linea evolutiva sono:

Vaswani et al. (2017) [1]: introducono l'architettura Transformer e il meccanismo di auto-attenzione (*Self-Attention*) nel processamento del linguaggio naturale, gettando le basi matematiche per la modellazione delle relazioni a lungo raggio.

Carion et al. (2020)[2]: presentano DETR (*DEtection TRansformer*), il primo modello che trasla con successo i Transformer nella computer vision per il task di object detection. Introducono il concetto fondamentale di *Object Queries* e ridefiniscono l'addestramento end-to-end tramite una loss basata su accoppiamento bipartito (*Bipartite Matching*), eliminando la necessità di euristiche come la *Non-Maximum Suppression* (NMS).

Cheng et al. (2021)[3]: formulano l'architettura *MaskFormer*, il diretto antenato del modello in esame. Dimostrano sperimentalmente che il paradigma della *Mask Classification* (compo-

sta dalla predizione di un insieme di maschere binarie associata a una classificazione globale della maschera stessa) è intrinsecamente superiore alla classificazione per-pixel classica e può unificare i task di segmentazione semantica e panottica.

Cheng, Misra, Schwing, Kirillov e Gir-dhar (2022)[4]: pubblicano il lavoro definitivo su *Mask2Former* (*Masked-attention Mask Transformer for Universal Image Segmentation*). Gli autori introducono l'innovazione della *Masked Attention* e l'utilizzo di feature multi-scala ad alta risoluzione per risolvere i limiti storici di convergenza lenta e scarsa accuratezza sui micro-oggetti tipici dei modelli precedenti.

2.2 Rassegne e Sviluppi Correlati

Parallelamente allo sviluppo di Mask2Former, la comunità scientifica ha esplorato varianti e ottimizzazioni per migliorare l'efficienza dei meccanismi di set prediction.

Gao et al. (2021)[5]: propongono lo schema SMCA (*Spatially Modulated Co-Attention*), esplorando la convergenza rapida dei Transformer tramite modulazione spaziale gaussiana delle mappe di attenzione.

Zhang et al. (2021)[6]: introducono l'algoritmo *K-Net*, un framework concorrente orientato alla segmentazione unificata che sostituisce la cross-attenzione con un'operazione di *mask pooling* dinamico all'interno dei kernel di segmentazione.

Zhu et al. (2021)[7]: sviluppano *Deformable DETR*, introducendo il modulo di attenzione deformabile multi-scala (*MSDeformAttn*) per mitigare la complessità computazionale quadratica dell'attenzione globale, tecnologia successivamente integrata nel Pixel Decoder nativo di Mask2Former.

2.3 Standardizzazione Applicativa

Il consolidamento e la diffusione su larga scala di Mask2Former sono stati fortemente supportati dalla sua integrazione all'interno di librerie software open-source di riferimento industriale e accademico.

La standardizzazione operata all'interno del framework *Detectron2* di Meta AI e, successivamente, la documentazione e il rilascio dei pesi pre-addestrati nella libreria *Hugging Face Transformers*, hanno reso questo algoritmo il benchmark di riferimento universale. Tali piattaforme ne hanno validato l'efficacia non solo su dataset accademici classici — come [COCO](#) e [ADE20K](#) — ma ne hanno esteso l'utilizzo a contesti applicativi complessi e verticali, quali la segmentazione medica ad alta fedeltà e, come analizzato nel presente report, il telerilevamento satellitare di contesti urbani.

3 Case Study: Il Dataset Dubai

L'applicazione di modelli di *universal image segmentation* nel dominio dell'osservazione della Terra (*Earth Observation*) rappresenta una frontiera tecnologica di forte interesse ingegneristico. A differenza dei dataset accademici classici di computer vision, le immagini catturate da sensori orbitali presentano una prospettiva zenitale (*nadir*), un'elevatissima densità di strutture geometriche e uno sbilanciamento intrinseco delle classi al suolo.

Per convalidare le capacità di segmentazione d'istanza dell'architettura Mask2Former in un contesto applicativo reale, il presente lavoro adotta come caso studio il dataset pubblico di immagini satellitari ad alta risoluzione della città di [Dubai](#).

3.1 Caratteristiche del Dataset

Il dataset è composto da ortofoto satellitari multispettrali catturate dal sensore *DubaiSat-2*. Ciascuna immagine ad alta risoluzione è stata ritagliata in tasselli (*tiles*) geometrici regolari per consentire la manipolazione tensoriale e la gestione dei vincoli di memoria vRAM durante la pipeline di addestramento.

Le immagini presentano una combinazione complessa di strutture antropiche moderne e morfologia desertica naturale, rendendo il compito di estrazione dei contorni un banco di prova ideale per l'operatore di *Masked Attention*.

3.2 Tassonomia delle Classi Semantiche

Il dataset mappa la superficie urbana e naturale distribuendo i pixel del dominio su 6 classi fondamentali, le quali riflettono la tipica etero-

geneità dei contesti costieri e urbani del Medio Oriente. Dal punto di vista della segmentazione d'istanza, le classi vengono gestite separando gli elementi discreti (*things*) dagli elementi continui di sfondo (*stuff*):

1. Buildings (Edifici - *Things*): rappresenta la classe target principale di questo studio. Include strutture residenziali, grattacieli e complessi industriali. Dal punto di vista geometrico, presenta variazioni di scala estreme e forti distorsioni prospettiche dovute all'angolo di inclinazione del satellite, oltre a proiettare ombre asimmetriche sul suolo.

2. Roads (Strade - *Stuff/Things*): la rete viaria asfaltata della città. Si sviluppa in modo continuo e interseca pixel appartenenti a texture di auto o ombreggiature, richiedendo al modello una forte coerenza nel tracciamento dei confini.

3. Water (Acqua - *Stuff*): canali artificiali, piscine, bacini idrici e porzioni di mare. Dal punto di vista spettrale, questa classe mostra repentine variazioni di colore a seconda della profondità e del riflesso solare.

4. Land (Terreno/Deserto - *Stuff*): aree desertiche non edificate, sabbia aperta e suolo arido. Costituisce la classe maggioritaria in termini di pixel totali, fungendo da background principale.

5. Vegetation (Vegetazione - *Stuff*): parchi urbani, palmeti e zone coltivate artificialmente. Presenta una firma spettrale nel vicino infrarosso molto marcata, ma confini geometrici frastagliati.

6. Natural (Elementi Naturali Vari - *Stuff*): formazioni rocciose o geomorfologiche non classificabili come semplice sabbia desertica.

3.3 Sfide Ingegneristiche del Dominio

L'addestramento di Mask2Former su questo dataset introduce tre sfide metodologiche che differenziano il telerilevamento dalla computer vision standard:

3.3.1 Sbilanciamento delle Classi

Le classi *Land* e *Water* occupano ampie porzioni continue di pixel, mentre gli oggetti discreti della classe *Buildings* (fondamentali per la segmentazione d'istanza) si concentrano in cluster densi e occupano una percentuale volumetrica ridotta dell'immagine complessiva. Questo fenomeno introduce il rischio di gradienti dominati dallo sfondo, problema mitigato matematicamente in Mask2Former grazie al bilanciamento operato dalla loss combinata Cross-Entropy e Dice Loss calcolata sui punti.

3.3.2 Risoluzione Spaziale e Micro-Oggetti

Molti edifici isolati o strutture minori appaiono come piccoli gruppi di pochi pixel. I Transformer standard falliscono nel catturare queste istanze a causa della perdita di risoluzione nei livelli profondi del backbone. L'utilizzo del Pixel Decoder avanzato basato su *MSDeformAttn* all'interno di Mask2Former diventa quindi cruciale per recuperare i dettagli a scala $1/8$ e $1/4$.

3.3.3 Effetto dell'Illuminazione e Ombre

Le ombre proiettate dagli edifici alti alterano la firma spettrale dell'asfalto (*Roads*) e della sabbia (*Land*). Il modello deve imparare ad associare la maschera geometrica dell'edificio separandola dalla sua ombra proiettata, la quale non deve essere erroneamente inclusa nel conteggio d'istanza.




Figura 1: Tassello (*tile*) satellitare di input ad alta risoluzione in modalità RGB spettrale.



Figura 2: Mappa di segmentazione (*Ground Truth*) associata, codificata a colori per l'addestramento multiclasse.

4 Metodologia e Architettura di Dettaglio

La robustezza di Mask2Former risiede nella sua formulazione metodologica, orientata a trattare qualsiasi compito di segmentazione attraverso il paradigma unificato della *Mask Classification*. Questa sezione analizza la scomposizione matematica e l'architettura macroscopica del modello, definendo le interazioni tra i moduli computazionali che governano il flusso dei tensori.

4.1 Pipeline Sequenziale e Flusso dei Dati

Il flusso di processing delle informazioni all'interno del modello si articola attraverso una pipeline sequenziale a tre stadi fondamentali, progettata per estrarre, raffinare e decodificare le feature geometriche e spaziali della scena:

1. Backbone: L'immagine satellitare subisce una compressione spaziale progressiva tramite una spina dorsale convoluzionale (es. ResNet) o basata su Transformer visivi. Questo modulo estrae mappe di feature a bassa risoluzione ma caratterizzate da un ricco contesto semantico globale.

2. Pixel Decoder: Un modulo avanzato basato su meccanismi di *Multi-Scale Deformable Attention (MSDeformAttn)*. Il suo compito è upscalare (ovvero aumentare la risoluzione spaziale) le feature map rimpicciolite dal backbone per costruire una piramide multi-scala a risoluzioni $1/32$, $1/16$ e $1/8$ rispetto alla dimensione nativa. Parallelamente, genera un embedding per-pixel ad alta risoluzione pari a $1/4$ della dimensione originale dell'immagine, fondamentale per la precisione dei contorni.

3. Transformer Decoder: Il nucleo algoritmico del sistema. Un insieme fissato di $N =$

100 *Object Queries* (vettori continui apprendibili) interagisce con i livelli della piramide multi-scala in modalità *round-robin*. L'interazione è governata dall'operatore di **Masked Attention**, che vincola geometricamente il gradiente.




Figura 3: Architettura macroscopica di Mask2Former: integrazione sequenziale tra Backbone, Pixel Decoder e Transformer Decoder [4].

4.2 Formulazione della Masked Attention

Nelle architetture Transformer tradizionali, l'attenzione standard calcola l'affinità globale tra le Query ($\mathbf{Q}$) e i Key ($\mathbf{K}$) tramite il prodotto scalare diretto, come espresso dalla relazione:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}(\mathbf{Q}\mathbf{K}^T)\mathbf{V} \quad (1)$$

Questo meccanismo consente a ciascuna query di estrarre informazioni dall'intera estensione spaziale della feature map, introducendo tuttavia una convergenza estremamente lenta nei task di segmentazione a causa del rumore dello sfondo.

Al contrario, la *Masked Attention* introdotta in Mask2Former modula localmente la matrice di affinità sommando algebricamente una matrice di mascheramento $\mathcal{M}_{l-1}$ prima del calcolo

del Softmax:

$$\text{MA}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}(\mathcal{M}_{l-1} + \mathbf{Q}\mathbf{K}^T)\mathbf{V} \quad (2)$$

I coefficienti della matrice di mascheramento $\mathcal{M}_{l-1}$ applicata al livello corrente l del decoder sono determinati in modo rigoroso e binarizzato sulla base della maschera d'istanza binarizzata M_{l-1} predetta al passo precedente ($l - 1$) per ciascuna coordinata spaziale (x, y) :

$$\mathcal{M}_{l-1}(x, y) = \begin{cases} 0 & \text{se } M_{l-1}(x, y) = 1 \\ -\infty & \text{altrimenti} \end{cases} \quad (3)$$

Attraverso questa formulazione, l'introduzione del valore $-\infty$ nelle regioni di background annulla matematicamente i corrispondenti pesi dell'attenzione in seguito all'operazione di Softmax ($e^{-\infty} = 0$). Di conseguenza, la singola query è forzata a focalizzare l'aggiornamento dei propri pesi esclusivamente all'interno delle regioni di primo piano (*foreground*), accelerando la discesa del gradiente.

4.3 Set Prediction e Bipartite Matching Loss

Come formalizzato nel capitolo 3 del paper originale, Mask2Former modella la segmentazione non come un problema di classificazione per-pixel, ma come un problema di predizione di insiemi (*Set Prediction*).

All'uscita del Transformer Decoder, i vettori delle query vengono proiettati in parallelo verso due teste lineari distinte: una *Class Head*, che genera i logit di classificazione categoriale (inclusa la classe vuota $\emptyset$), e una *Mask Head*, che decodifica le N maschere binarie finali tramite prodotto scalare con l'embedding a 1/4 del Pixel Decoder.

L'addestramento end-to-end mappa l'insieme delle N predizioni sull'insieme delle N_{gt} maschere reali attraverso un accoppiamento bipartito (*Bipartite Matching*) risolto tramite l'algoritmo ungherese. La funzione di loss complessiva applicata a ciascuna query accoppiata è una combinazione lineare di tre componenti fondamentali:

$$\mathcal{L}_{total} = \lambda_{cls}\mathcal{L}_{cls} + \lambda_{mask}\mathcal{L}_{mask} \quad (4)$$

dove la loss della maschera $\mathcal{L}_{mask}$ unisce in modo additivo la Binary Cross-Entropy Loss e la Dice Loss:

$$\mathcal{L}_{mask} = \lambda_{bce}\mathcal{L}_{bce} + \lambda_{dice}\mathcal{L}_{dice} \quad (5)$$

4.4 Efficienza di Memoria tramite Point-Based Loss

Un limite computazionale storico della classificazione a maschere è l'elevato consumo di memoria GPU richiesto per calcolare $\mathcal{L}_{mask}$ su matrici binarie ad alta risoluzione. Per aggirare questo vincolo, Mask2Former introduce una strategia parsimoniosa basata su campionamento di punti (*Point-Based Loss*).

Invece di calcolare la loss sull'intera griglia spaziale della maschera, la funzione di costo viene valutata esclusivamente su un subset di $K = 12544$ punti strategici per immagine. Questo subset viene selezionato combinando un campionamento casuale uniforme con un campionamento guidato dall'incertezza (*importance sampling*), focalizzato sui pixel incerti posizionati lungo i bordi frastagliati degli oggetti. Ciò consente una riduzione simmetrica della memoria di training da 18GB a soli 6GB, preservando intatta l'accuratezza geometrica.

5 Progettazione e Implementazione Software

L'ambiente in cui è stato sviluppato il progetto consiste nei notebook Kaggle. La prima sezione si sofferma sulla progettazione modulare del *Pixel Decoder* implementato in PyTorch puro, descrivendo le scelte di semplificazione architetturale volte a eliminare le dipendenze da framework esterni come *Detectron2* o *fvcore*.

5.1 Pixel Decoder

Il Pixel Decoder si posiziona immediatamente a valle del backbone computazionale ed agisce come ponte tra le feature semantiche del backbone e la risoluzione necessaria per le maschere. Assolve due compiti critici all'interno del flusso tensoriale:

1. **Generazione di Feature Multi-Scala:** Costruisce una struttura piramidale ad alta risoluzione, indispensabile per consentire alle Object Queries di rilevare micro-oggetti e confini netti (quali complessi edifici e reti viarie) nei dati satellitari.
2. **Estrazione delle Mask Features:** Produce un embedding finale denso e bidimensionale ($\mathbf{F}_{mask}$), destinato a subire un prodotto scalare con i vettori in uscita dal Transformer Decoder per generare le maschere binarie finali.

5.1.1 Rottura delle Dipendenze e Semplificazione

Nelle implementazioni standard di Mask2Former, i blocchi di upsampling e le convoluzioni sono incapsulati in classi proprietarie di Detectron2 che si appoggiano a librerie C++ ottimizzate.

Per garantire la massima portabilità e facilità di debug senza compromettere l'efficienza algoritmica, la struttura è stata reingegnerizzata sfruttando esclusivamente le primitive native di PyTorch:

- I layer convoluzionali custom sono stati sostituiti dal modulo standard `nn.Conv2d`, accoppiato a livelli di `nn.BatchNorm2d` per stabilizzare la distribuzione dei gradienti.
- L'upsampling Top-Down della Feature Pyramid Network (FPN) è stato implementato tramite interpolazione geometrica *nearest-neighbor* mediante la funzione nativa `nn.functional.interpolate`.
- Il nucleo di Self-Attention globale è stato modellato riutilizzando le classi `nn.TransformerEncoder` e `nn.TransformerEncoderLayer`.

L'adozione del Transformer Encoder sul livello più profondo del backbone (`res5`) è l'innovazione metodologica cardine. Mentre le convoluzioni standard possiedono un campo ricettivo (*receptive field*) limitato e locale, l'operatore di Self-Attention globale consente a ciascun pixel della mappa a bassa risoluzione (8×8) di dialogare con qualsiasi altra locazione spaziale dell'immagine, catturando relazioni macro-urbane fondamentali nel telerilevamento.

5.1.2 Codice Sorgente in PyTorch Puro

Elemento fondamentale del codice del Pixel Decoder è la classe `PurePyTorchPixelDecoder`. Il codice accetta in input una lista di tensori estratti dal backbone, inverte l'ordine per attuare il ciclo Top-Down ed estrae i livelli multi-scala richiesti.

All'inizializzazione (`__init__`) il codice inverte l'ordine delle caratteristiche (`[::-1]`) per elaborarle in modalità Top-Down (dalla risoluzione

più bassa a quella più alta). Le *feature_channels* sono la lista dei canali in output dal backbone (es. [res2, res3, res4, res5] di una ResNet), *conv_dim* è la dimensione dei canali interni per la Feature Pyramid Network (FPN) e la *mask_dim* è la dimensione dei canali per la mask feature finale. Il modulo nativo PyTorch del Transformer Encoder elabora le feature globali a bassa risoluzione. Sono presenti poi due tipi di convoluzioni per la struttura Top-Down (FPN):

1. *lateral_convs* (Convoluzioni Laterali): Convoluzioni 1x1 che uniformano il numero di canali di ogni livello del backbone portandoli a un valore fisso (conv_dim).
2. *output_convs* (Convoluzioni di Output): Convoluzioni 3x3 che fondono le informazioni e riducono gli artefatti dovuti all'upsampling.

Per l'ultimo livello (res5), c'è solo una convoluzione di output 3x3 dopo il Transformer, mentre per gli altri livelli (da res4 scendendo fino a res2) vengono creati i blocchi convoluzionali. Vi è poi una convoluzione finale per generare le *mask_features* dense ad alta risoluzione.

Il nucleo algoritmico consiste poi nel passaggio in avanti (*forward pass*). Il codice mappa la manipolazione geometrica dei tensori ed implementa la filosofia progettuale del progetto.

Tale implementazione evidenzia tre scelte architetturali determinanti per la segmentazione di immagini satellitari:

- I moduli Transformer lavorano nativamente su sequenze monodimensionali di token. L'operazione `x_proj.flatten(2).permute(0, 2, 1)` funge da ponte matematico, destrutturando le dimensioni spaziali dell'immagine ($H \times W$) in una sequenza continua.
- Il passaggio del livello **res5** (ridotto a una griglia 8×8) all'interno del **Transformer**

Encoder consente a ciascun pixel di dialogare con qualsiasi altra locazione dell'immagine, indipendentemente dalla distanza spaziale. Nelle ortofoto satellitari, questo meccanismo a lungo raggio è cruciale: permette alla rete di disambiguare la classe di una specifica area grigia (distinguendo ad esempio un tetto industriale da un segmento stradale) analizzando il contesto circostante globale.

- Il ciclo iterativo mappa la Feature Pyramid Network (FPN). L'operazione `F.interpolate(..., mode="nearest")` ingrandisce la mappa precedente `y` per adeguarla alle dimensioni della mappa corrente `cur_fpn`. La successiva somma algebrica unisce il contesto semantico raffinato con i dettagli geometrici ad alta risoluzione del livello corrente, mentre le convoluzioni 3×3 (**output_convs**) abbattano gli artefatti tipici dell'upsampling.

Infine per escludere sfasamenti geometrici, l'esecuzione del forward pass è stata validata su Kaggle simulando le feature map di un'immagine satellitare (con batch pari a 2). Il modello ha risposto rispettando perfettamente i vincoli dimensionali attesi:

- **mask_features_out**: [2, 256, 64, 64]. Dimensione ad alta risoluzione spaziale (pari a 1/4 della nativa), ideale per preservare la precisione dei contorni.
- **transformer_encoder_features**: [2, 256, 8, 8]. Il livello semantico più profondo arricchito dall'attenzione globale.
- **multi_scale_features**: Una lista di 3 tensori strutturati a scale progressive (8×8 , 16×16 , 32×32), pronti per guidare il Transformer Decoder.

5.2 Transformer Decoder

L'elemento più innovativo di Mask2Former è il *Multi-Scale Masked Transformer Decoder*. Rispetto ai Transformer tradizionali (e al precedente modello MaskFormer), gli autori di Meta hanno introdotto due grandi rivoluzioni in questo blocco:

1. L'ordine dei layer invertito: si esegue la *Cross-Attention* prima della *Self-Attention*.
2. La *Masked Attention Multi-Scale*: l'attenzione vincolata estrae dettagli ciclicamente da 3 scale diverse di risoluzione, ottimizzando le prestazioni su oggetti piccoli e grandi (fondamentale ad esempio per le immagini satellitari).

5.2.1 Cross-Attention e Self-Attention

Entrambi i meccanismi usano gli stessi tre vettori matematici fondamentali: *Query (Q)*, *Key (K)* e *Value (V)*. La vera differenza sta unicamente da dove arrivano questi vettori. Nella *Self-Attention*, tutti e tre i vettori (*Q*, *K*, *V*) nascono dalla stessa identica sequenza di input. Il suo obiettivo è fare in modo che ogni elemento della sequenza dialoghi con tutti gli altri elementi della stessa sequenza per capire il contesto globale. Se l'input è un'immagine satellitare, la *Self-Attention* permette a un pixel che rappresenta un "pezzo di tetto" di guardare tutti gli altri pixel della stessa immagine. In questo modo capisce se si trova all'interno di un quartiere residenziale o di una zona industriale isolata. In *Mask2Former* è usata tra gli *object query*, ovvero i vettori che vanno a caccia degli oggetti, in modo tale che due vettori non traccino ad esempio lo stesso edificio.

Nella *Cross-Attention*, i vettori arrivano da due sorgenti diverse. In particolare:

- Le *Query (Q)* arrivano da una prima sequenza (es. i target da predire o un'altra modalità).
- Le *Key (K)* e i *Value (V)* arrivano da una seconda sequenza differente (che fa da memoria di contesto).

Ad esempio, nel caso in cui ci fosse una lista di 100 domande vuote (*Query*) e una foto satellitare (la memoria *K* e *V*), la *Cross-Attention* permette a ciascuna domanda di scorrere i pixel della foto, calcolare dove c'è la massima affinità matematica e estrarre solo le informazioni geometriche che le servono per ricostruire la forma di un oggetto. In Mask2Former è il meccanismo che unisce l'Encoder e il Decoder e le *Queries* del Transformer estraggono le caratteristiche geometriche dell'immagine satellitare generate dal *Pixel Decoder*.

Nel codice originario del *Transformer Decoder* sono definiti tre moduli che vengono poi assemblati sequenzialmente per formare ogni singolo strato del decoder:

- **SelfAttentionLayer**: gestisce il dialogo interno tra i vari *Object Query*. Serve a fare in modo che i diversi vettori imparabili non si sovrappongano, focalizzandosi su oggetti o segmenti di terreno differenti.
- **CrossAttentionLayer**: è il punto in cui avviene la *Masked Attention*. I *Query* estraggono informazioni semantiche e geometriche direttamente dalle feature dell'immagine satellitare (memory), ma il calcolo viene condizionato da una maschera (*memory_mask*).
- **FFNLayer / MLP**: classici strati lineari densi (*Feed-Forward Network*) accoppiati a funzioni di attivazione (come ReLU o GeLU) che aggiungono non-linearità

e proiettano i vettori alle dimensioni di output finali.

5.2.2 Implementazione dello Strato del Decoder

Per tradurre in codice la scomposizione logica discussa, ciascun livello del decoder è stato modellato assemblando in modo sequenziale tre moduli nativi di `torch.nn`, adottando una configurazione *Pre-LayerNorm* (Pre-LN) per stabilizzare la discesa del gradiente.

Il codice seguente mappa il singolo strato computazionale, integrando l'alimentazione dei *Positional Embedding* a Query e Key, e applicando la maschera di vincolo geometrico:

```
def forward(self, tgt, memory,
            query_pos=None, pos=None,
            attn_mask=None):
    # 1. MASKED CROSS-ATTENTION
    (Pre-LN)
    tgt_norm = self.norm1(tgt)
    q = tgt_norm if query_pos
        is None else tgt_norm +
        query_pos
    k = memory if pos is None
        else memory + pos
    v = memory

    tgt2 = self.cross_attn(
        query=q, key=k, value=v
        , attn_mask=
        attn_mask
    )[0]
    tgt = tgt + self.dropout1(
        tgt2)

    # 2. SELF-ATTENTION (Pre-LN)
    )
    tgt_norm = self.norm2(tgt)
    q = tgt_norm if query_pos
        is None else tgt_norm +
        query_pos
```

```
tgt2 = self.self_attn(
    query=q, key=q, value=
    tgt_norm
)[0]
tgt = tgt + self.dropout2(
    tgt2)

# 3. FEED-FORWARD NETWORK (
Pre-LN)
tgt_norm = self.norm3(tgt)
tgt2 = self.linear2(self.
    dropout3(
        self.activation(self.
            linear1(tgt_norm))
    ))
tgt = tgt + self.dropout3(
    tgt2)

return tgt
```

5.2.3 Architettura del Decoder Completo

Il modulo `PurePyTorchMask2FormerDecoder` unifica gli strati computazionali implementando il ciclo ricorsivo sulle tre scale della piramide di feature, gestendo le uscite ausiliarie per la loss intermedia e calcolando la proiezione a pixel tramite contrazione tensoriale (*Einsum*).

L'architettura del decoder poggia su tre implementazioni software critiche:

- **Einsum e Contrazione Tensoriale della Maschera** La generazione parallela delle $N = 100$ maschere di segmentazione ad alta risoluzione avviene tramite l'istruzione `torch.einsum("bqc,bchw->bqhw", ...)`. Questa operazione esegue una contrazione tensoriale (prodotto scalare ottimizzato in CUDA) tra la matrice di embedding delle query prodotta dalla *Mask Head* e le *mask_features* dense estratte dal Pixel

Decoder, iniettando la massima efficienza hardware durante il forward pass.

- **Meccanismo di Safe Masking Anti-NaN**

Nella funzione `forward_prediction_heads`, l'estrazione di `attn_mask` binarizza la mappa tramite una soglia probabilistica impostata a 0.5. All'interno della classe `MultiheadAttention` nativa di PyTorch, i pixel mappati a `True` vengono scartati imponendo il peso dell'attenzione a $-\infty$.

Tuttavia, se una query escludesse per errore l'intero dominio spaziale dell'immagine satellitare, la riga risulterebbe interamente pari a `True`, portando il denominatore della funzione Softmax a zero e iniettando valori instabili (NaN) nel gradiente. L'istruzione `torch.where(all_true, ...)` corregge preventivamente questa anomalia resettando la riga a `False` (forzando la query a guardare tutta la scena), garantendo stabilità numerica.

- **Supervisione Intermedia e Output Ausiliari** Il dizionario di ritorno raccoglie sia i logit e le maschere finali, sia una lista `aux_outputs`. Questo blocco implementa la supervisione intermedia (calcolando la loss ungherese separatamente ad ogni epoca dei layer del decoder). Costringendo i pesi a raffinare le maschere un passo alla volta, si abbatte il rumore di fondo accelerando drasticamente i tempi di convergenza.

5.2.4 Esecuzione del Test Unificato

L'intera architettura software (Pixel Decoder unito al Masked Transformer Decoder) è stata validata interconnettendo i due macro-blocchi su un batch simulato di 2 immagini satellitari configu-

rate con 20 classi estrattive. I tensori di uscita hanno confermato la stabilità geometrica del grafo:

- `pred_logits`: `[2, 100, 21]`, contenente le densità di probabilità sulle 20 classi reali del terreno più la classe dello sfondo vuoto ($\emptyset$).
- `pred_masks`: `[2, 100, 64, 64]`, Ogni singolo query ha prodotto una maschera di segmentazione spaziale dettagliata alla risoluzione di 64×64 pixel.
- `aux_outputs`: 3 blocchi intermedi registrati con successo, validando l'impianto di calcolo della loss multi-strato.

5.3 Unificazione dell'Architettura Completa: ResNet

Per consolidare l'intero impianto algoritmico, i tre macro-moduli sviluppati (Backbone, Pixel Decoder e Masked Transformer Decoder) sono stati assemblati all'interno della classe principale `PurePyTorchMask2Former`.

Come spina dorsale computazionale è stata adottata una *ResNet50* pre-addestrata. Al fine di estrarre esclusivamente le mappe caratteristiche spaziali eliminando i vincoli di classificazione per-pixel, lo strato finale densamente connesso (*Fully Connected*) e il blocco di *Global Average Pooling* nativi del modello sono stati rimossi. Quindi nel modello unificato *PurePyTorchMask2Former* presente nel codice del Transformer Decoder, è stata presa una ResNet-50 standard ed è stata usata come Backbone (spina dorsale) per estrarre le caratteristiche dell'immagine. La ResNet fa il lavoro pesante iniziale: analizza l'immagine satellitare grazie ai suoi blocchi residuali e genera le mappe di feature multi-scala ricche di contesto (le famose *res2*, *res3*, *res4*,

res5) senza soffrire del problema del gradiente che svanisce. Queste mappe vengono poi raffinate dal Pixel Decoder e dal Transformer Decoder per creare le maschere di segmentazione finali.

5.4 Pipeline di Caricamento Dati

Per sfruttare nativamente l'estrazione delle maschere binarie, la ricerca è stata indirizzata verso il dataset *Dubai MBRSC (Mohammed Bin Rashid Space Centre) Aerial Imagery* [8], come già visto in precedenza, distribuito tramite la piattaforma Kaggle.

La classe di caricamento dei dati opera in modalità strettamente accoppiata (*paired input-target*). Per ciascuna ortofoto aerea (es. `image_001.jpg`), il sistema esegue una scansione e associa la corrispettiva mappa di verità geometrica (*Ground Truth*, es. `image_001.png`).

All'interno di queste maschere, i confini degli oggetti sono definiti da campiture di colore piatte e prive di sfumature cromatiche, dove ogni categoria corrisponde a una specifica classe del territorio: edifici, strade, terreno, acqua, vegetazione e sfondo non etichettato.

L'esplorazione del file system all'interno dell'ambiente di computazione ha evidenziato la seguente gerarchia di memorizzazione profonda:

```
/datasets/humansintheloop/  
  semantic-segmentation-of-aerial-imagery/  
    Semantic segmentation dataset/  
      Tile 1/ ... Tile 8/  
        classes.json
```

Le riprese satellitari ad altissima risoluzione della città di Dubai sono state suddivise in 8 grandi macro-aree geografiche denominate *Tile* (da *Tile 1* a *Tile 8*). Ogni directory ospita le ortofoto RGB nella sottocartella `images` ed i rispettivi target di segmentazione nella sotto-

cartella `masks`. Infine, il metadato `classes.json` mappa i vettori RGB associati a ciascuna classe del terreno.

Durante lo sviluppo della classe `SatelliteDataset`, è emersa una criticità fondamentale legata al formato di memorizzazione del Ground Truth. Nel dataset Dubai, le maschere non sono salvate come tensori mono-canale di indici, bensì come immagini a colori (RGB) in cui ogni categoria semantica è rappresentata da una specifica firma cromatica esadecimale (es. i palazzi sono delineati in viola scuro, l'acqua in giallo ocra).

Un approccio ingenuo basato sulla conversione dell'immagine in scala di grigi nativa (tramite operatori standard come `.convert("L")` di PIL) comporterebbe la corruzione irreversibile dei dati: l'algoritmo interpolerebbe le triplette RGB calcolandone l'intensità luminosa, trasformando i colori in valori continui casuali e distruggendo i codici identificativi discreti (ID) attesi dalla Loss Function.

Per preservare l'integrità matematica dei target, il caricamento dati è stato realizzato tramite un algoritmo di *Color Mapping* vettoriale. La pipeline analizza i pixel della maschera RGB e, tramite una contrazione tensoriale con un dizionario preimpostato, mappa deterministicamente ogni colore esatto verso il rispettivo ID di classe (da 0 a 5).

5.5 Vincoli Geometrici e Validazione End-to-End

L'allineamento dei dati reali all'interno del `DataLoader` introduce un ulteriore vincolo geometrico. La maschera subisce il medesimo ridimensionamento spaziale applicato all'immagine RGB, impostando il target a 256×256 pixel. Tuttavia, per le mappe di Ground Truth è strettamente obbligatorio impostare la modalità di interpolazione

a **Prossimo Vicino** (`InterpolationMode.NEAREST`).

L'adozione di filtri di scaling bilineari sulle maschere discrete genererebbe, infatti, pixel con ID decimali spuri lungo i bordi delle infrastrutture (es. classe 2.4), mandando in crash l'operatore di Cross-Entropy.

L'inizializzazione del framework con le trasformazioni ingegnerizzate ha indicizzato con successo 72 coppie stabili. Il test di inferenza end-to-end sul grafo unificato ha restituito i seguenti output:

- **Input RGB:** Tensore di forma `[2, 3, 256, 256]`.
- **Target Mappato (Ground Truth):** Matrice di tipo `[2, 256, 256]`. I colori RGB sono stati rimossi e ogni cella contiene ora un intero puro (0-5).
- **Output Mask2Former:** Tensore `[2, 100, 64, 64]`.

Il matching dimensionale conferma che l'architettura è idonea per la fase di ottimizzazione dei pesi tramite supervisione pixel-level.

6 Criterio di Loss e Fase di Addestramento

Una volta validata l'integrità geometrica e dimensionale dei tensori d'uscita, l'architettura viene immessa nella fase critica di ottimizzazione del gradiente. Questo capitolo analizza la formalizzazione matematica del criterio di errore personalizzato, la strategia di accoppiamento geometrico e le risposte numeriche iniziali fornite dal grafo computazionale unificato.

6.1 Il Concetto di Loss Function nel Telerilevamento

Nel contesto del Deep Learning applicato alla segmentazione d'immagini satellitari, la funzione di costo (*Loss Function*) rappresenta l'operatore matematico deputato a quantificare la distanza algebrica tra le stime predette dalla rete e la verità al suolo (*Ground Truth*).

Durante la fase iniziale di addestramento (*Forward Pass*), i pesi sinaptici del modello sono distribuiti secondo un'inizializzazione stocastica casuale; pertanto, l'elaborazione di un'ortofoto di Dubai produce mappe di confidenza altamente caotiche ed imprecise. La Loss Function confronta queste matrici predette con i target discreti del dataset, estraendo un valore numerico scalare indicativo dell'errore.

Tale punteggio governa la successiva fase di retropropagazione (*Backpropagation*): attraverso il calcolo differenziale dei gradienti, l'algoritmo di ottimizzazione modifica retroattivamente i pesi della rete neurale lungo l'intero grafo, forzando la convergenza e minimizzando lo scostamento geometrico nelle epoche successive.

6.2 Formalizzazione Matematica della Loss Combinata

Il paper originale di Mask2Former si affida a un paradigma basato sul *Bipartite Matching* tramite algoritmo ungherese, operazione computazionalmente onerosa se implementata al di fuori di framework pre-compilati. Per l'architettura snella in PyTorch puro sviluppata in questo progetto, è stata realizzata una strategia di loss custom che mappa in modalità locale e deterministica le risposte spaziali delle query sul dominio pixel-level.

La funzione di costo complessiva $\mathcal{L}_{total}$ si compone di una combinazione lineare di tre operatori indipendenti, calibrati per bilanciare la semantica d'immagine e la precisione geometrica dei vettori:

$$\mathcal{L}_{total} = \lambda_{cls}\mathcal{L}_{cls} + \lambda_{bce}\mathcal{L}_{bce} + \lambda_{dice}\mathcal{L}_{dice} \quad (6)$$

Dove i coefficienti di ponderazione sono stati impostati in modo iper-asimmetrico ($\lambda_{cls} = 1.0$, $\lambda_{bce} = 20.0$, $\lambda_{dice} = 20.0$) al fine di sovra-esaltare le penalità geometriche e forzare la rete a delineare confini netti e taglienti lungo le infrastrutture urbane.

- **Componente di Classificazione ($\mathcal{L}_{cls}$)**

La classificazione semantica delle query sfrutta l'operatore di Cross-Entropy multi-classe standard. Per ciascun vettore oggetto, la Loss valuta l'accuratezza delle probabilità generate dalla testa lineare (`pred_logits`) rispetto alla categoria mappata:

$$\mathcal{L}_{cls} = - \sum_c y_c \log(p_c) \quad (7)$$

Laddove una query non intercetti alcun elemento geometrico significativo del territorio, il target viene associato d'ufficio

alla classe vuota o di sfondo ($\emptyset$, codificata come *No-Object* all'indice *num_classes*)

- **Componente di Errore Binario Spaziale ($\mathcal{L}_{bce}$)** La Binary Cross-Entropy Loss agisce pixel-per-pixel sull'estensione bidimensionale della maschera prodotta da ogni singola query attiva:

$$\mathcal{L}_{bce} = -[g \log(\sigma(x)) + (1-g) \log(1-\sigma(x))] \quad (8)$$

L'operatore mappa la sigmoide $\sigma(x)$ delle attivazioni continue e stabilizza l'orientamento iniziale del gradiente, valutando se la maschera binaria copra la corretta coordinata geografica della scena satellitare.

- **Componente Geometrica di Sørensen-Dice ($\mathcal{L}_{dice}$)** Poiché le ortofoto del dataset Dubai presentano un forte sbilanciamento di classe — in cui elementi macroscopici come il deserto (*Land*) occupano la quasi totalità della griglia spaziale rispetto a cluster piccoli e densi come i tetti degli edifici (*Buildings*) — la sola ottimizzazione tramite BCE risulterebbe parziale e polarizzata. Si introduce pertanto la Dice Loss, definita come:

$$\mathcal{L}_{dice} = 1 - \frac{2 \sum_i p_i g_i + \epsilon}{\sum_i p_i^2 + \sum_i g_i^2 + \epsilon} \quad (9)$$

Dove p_i rappresenta il pixel sigmoideo predetto, g_i il Ground Truth binario corrispondente ed $\epsilon = 1.0$ un fattore di smoothing matematico per scongiurare divisioni per zero. Essendo basata sull'intersezione normalizzata delle aree e non sul conteggio assoluto dei pixel di background, la Dice Loss è intrinsecamente immune allo sbilanciamento delle classi, impedendo alle strutture urbane a scala ridotta di es-

sere matematicamente ignorate o surrogate dal gradiente dello sfondo dominatario.

6.3 Algoritmo di Assegnazione Hard-Assignment tramite Argmax Spaziale

Il fulcro metodologico della funzione di costo custom risiede nel meccanismo di ripartizione del territorio tra le $N = 100$ query disponibili. Un'immagine satellitare reale ospita simultaneamente un sotto-insieme ridotto delle classi globali (spesso solo 3 o 4 categorie su 6 disponibili).

Per forzare le query a dividersi la scena in modo chirurgico ed evitare che più vettori convergano in modo ridondante sulla medesima porzione di suolo, è stata sviluppata una logica di allocazione competitiva basata su un **Argmax Spaziale**.

Invece di analizzare ciascuna maschera isolatamente applicando una soglia statica, l'algoritmo esamina ogni singolo pixel delle dimensioni interne del Pixel Decoder (64×64) e risolve il seguente quesito competitivo:

$$q_{winner}(x, y) = \arg \max_{q \in \{1, \dots, 100\}} \mathcal{M}_q(x, y) \quad (10)$$

In questo modo, la query q assume la titolarità esclusiva delle sole coordinate geografiche in cui ha espresso l'attivazione numerica più alta in assoluto rispetto ai rimanenti 99 vettori concorrenti. Se una riga di pixel vinta da una query presenta un'intersezione reale con il Ground Truth, la Loss estrae la classe dominante in quella micro-regione tramite operatore statistico di *Moda* (`torch.mode`) e ne calcola l'errore geometrico (BCE + Dice) ed il costo di classificazione sulla categoria reale corrispondente. Al contrario, se la query ha vinto aree vuote o non ha registrato attivazioni dominan-

ti al suolo, viene istantaneamente declassata e assegnata alla categoria *No-Object* ($\emptyset$).

6.4 Analisi Quantitativa del Test della Loss Iniziale

L'affidabilità algebrica e la stabilità del gradiente della Loss custom sono state verificate iniettando il batch reale da due immagini precedentemente estratto dal DataLoader di Dubai. L'output numerico registrato ha fornito i seguenti riscontri diagnostici:

- **Loss Totale Calcolata:** 10.6623
- **Componente Classificazione ($\mathcal{L}_{cls}$):** 1.9474
- **Componente Spaziale BCE ($\mathcal{L}_{bce}$):** 0.2662
- **Componente Geometrica DICE ($\mathcal{L}_{dice}$):** 0.1695

Questo specifico comportamento iniziale rappresenta una validazione metodologica perfetta della teoria dell'apprendimento profondo. Poiché la rete opera con pesi stocastici puramente casuali, non possiede alcuna competenza estrattiva e assegna le probabilità in modo uniforme. Dal punto di vista della teoria dell'informazione, il calcolo della Cross-Entropy per una scelta equiprobabile distribuita su 7 classi (6 reali + lo sfondo vuoto $\emptyset$) corrisponde matematicamente a $-\ln(1/7) \approx 1.945$. Il riscontro empirico di $\mathcal{L}_{cls} = 1.9474$ conferma l'assoluta correttezza formale dell'implementazione PyTorch.

Parallelamente, l'attivazione delle componenti geometriche ($\mathcal{L}_{bce}$ e $\mathcal{L}_{dice}$) dimostra l'efficacia del matching spaziale. A differenza di una classificazione globale, la rete tenta di sovrapporre maschere casuali (rumore) alle forme reali e complesse del Ground Truth (edifici, strade). Il

disallineamento morfologico tra il rumore predetto e la verità al suolo genera un errore di base che, amplificato dai moltiplicatori di ponderazione ($\lambda = 20.0$), spinge la Loss Totale a un valore di 10.6623. Questo elevato scostamento iniziale garantisce l'innescio di gradienti sufficientemente ripidi da avviare la discesa verso il minimo globale fin dalla prima epoca.

6.5 Protocollo di Addestramento e Configurazione degli Iperparametri

Il processo di ottimizzazione stocastica dei pesi sinaptici è stato condotto impostando una finestra temporale di addestramento pari a 15 epoche complete sul dataset accoppiato di Dubai, un volume computazionale ritenuto ottimale per osservare la stabilizzazione del gradiente ed evitare fenomeni di *overfitting*.

La velocità di apprendimento (*Learning Rate*) è stata calibrata al valore standard di $\eta = 10^{-4}$, ideale per governare le dinamiche estrattive dei moduli basati su attenzione. Come motore algoritmico per l'aggiornamento dei pesi è stato selezionato l'ottimizzatore **AdamW** (*Adam with Weight Decay*), impostando una regolarizzazione L2 pari a 10^{-4} per prevenire la deriva numerica dei parametri.

Al fine di mitigare il rischio di *Gradient Explosion* — un'instabilità tipica delle architetture Transformer in PyTorch in cui i gradienti accumulati nei passaggi profondi subiscono una crescita esponenziale — è stato integrato un meccanismo di protezione tramite la tecnica del **Gradient Clipping**, troncando la norma massima dei vettori di gradiente a una soglia rigida pari a 0.01.

6.6 Analisi della Dinamica di Convergenza e delle Curve di Loss

L'osservazione dei log storici registrati durante le 15 epoche evidenzia una convergenza complessa e altamente informativa sotto il profilo della teoria dell'apprendimento computazionale.




Figura 4: Andamento delle curve di Loss. La Loss Totale (viola) include le penalità moltiplicative applicate alle componenti geometriche.

L'andamento della Loss Totale esordisce a un valore critico elevato (superiore a 22.0), confermando che il modello, inizializzato con pesi stocastici, sta subendo la massima penalizzazione nel tentativo di mappare i quasi 300.000 pixel di ogni batch. Tuttavia, già entro le prime 5 epoche si assiste a una discesa ripida e costante, con la curva che converge verso un valore di stabilità prossimo a 5.0.

Le componenti di Classificazione e Geometrica mantengono valori assoluti inferiori per via della loro natura normalizzata, ma la loro discesa costante conferma il successo della strategia di *Argmax Spaziale*: le query si sono attivamente ripartite il territorio e hanno appreso a delineare i contorni reali delle infrastrutture superando il disallineamento iniziale. Il tipico andamento a "dente di sega" è giustificabile dalla natura del dataset Dubai, le cui inquadrature spaziali oscillano bruscamente da macro-aree ad alta densità urbana a scenari dominati esclusivamente dal deserto.

6.7 Analisi Pixel-Level tramite Matrice di Confusione

Per valutare la robustezza predittiva del modello sui dati reali, al termine dell'addestramento è stata generata una Matrice di Confusione normalizzata, calcolata pixel-per-pixel sull'intero volume del dataset.




Figura 5: Matrice di Confusione normalizzata calcolata pixel-per-pixel sulle 6 classi del dataset Dubai.

I risultati estratti evidenziano la convergenza eccellente su macro-aree continue: le classi *Water* (Acqua) e *Land* (Terreno/Deserto) registrano tassi di accuratezza diagonale rispettivamente del 99% e dell'89%. Nonostante la complessità geometrica dei contesti urbani, il modello ha isolato correttamente il 75% dei pixel appartenenti agli edifici. Il 17% di confusione residuale con la classe *Land* è morfologicamente giustificabile: le coperture piane di molte infrastrutture di Dubai presentano firme spettrali (colori) quasi indistinguibili dal deserto circostante. Infine, l'accuratezza nulla sulle classi *Vegetation* e *Natural* riflette un classico sbilanciamento del dataset (scarsa presenza di vegetazione), spingendo il classificatore a rias-

sorbire questi rari pixel all'interno delle classi dominanti.

d'interesse. L'architettura è matematicamente stabile, ha appreso la segmentazione del territorio ed è pronta per l'inferenza.

6.8 Ispezione Diagnostica Finale e Analisi Spettrale delle Query

Al fine di escludere anomalie sistemiche note in letteratura come il *Feature Collapse* (un collasso spettrale in cui tutte le query convergono verso la medesima rappresentazione vettoriale identica), al termine dell'addestramento è stata eseguita una scansione diagnostica sui logit estratti dal tensore di output delle maschere [2, 100, 64, 64]. L'analisi statistica applicata a una query campione ha registrato i seguenti indici metrici:

- **Valore Logit Massimo:** +0.3188
- **Valore Logit Minimo:** -1.6319
- **Valore Logit Medio:** -0.5698
- **Deviazione Standard (σ):** 0.3517

I parametri estratti convalidano sperimentalmente la corretta specializzazione dell'architettura. In primo luogo, l'assenza totale di valori non definiti (*NaN*) o infiniti all'interno dell'intera matrice attesta la perfetta stabilità algebrica della loss custom e dei gradienti normalizzati.

In secondo luogo, l'analisi distribuzionale conferma la dinamica ideale di un modello Mask2Former perfettamente funzionante: il valore medio negativo (-0.5698) indica che la query tende a disattivarsi sulla maggior parte della scena (rifiutando lo sfondo o le classi non di competenza), mentre la presenza di picchi positivi (+0.3188) e una varianza stabile ($\sigma = 0.3517$) dimostrano che l'embedding ha imparato a focalizzarsi in modo chirurgico e selettivo sulle sole istanze

7 Conclusioni e Sviluppi Futuri

Il presente lavoro di ricerca ha documentato con successo l'ingegnerizzazione, la traduzione algoritmica e la validazione sperimentale di un'architettura *Mask2Former* nativa, sviluppata integralmente in PyTorch puro, applicata alla segmentazione semantica pixel-level del territorio urbano e naturale della città di Dubai.

L'eliminazione strategica di dipendenze software da framework esterni complessi — quali *Detectron2* o *fvcore* — ha permesso di mappare e comprendere appieno i flussi tensoriali che governano il modello. La sinergia tra la compressione multi-scala operata dal Pixel Decoder e la successiva ripartizione del territorio tramite l'algoritmo competitivo di *Argmax Spaziale* ha dimostrato un'elevata stabilità numerica, confermata da un valore di Cross-Entropy iniziale perfettamente allineato con i vincoli stocastici della teoria dell'informazione.

Un traguardo ingegneristico centrale della pipeline sviluppata risiede nella persistenza dei parametri ottimali del modello, consolidati al termine del ciclo di addestramento all'interno del file dei pesi `mask2former_dubai_final.pth`. Questo file non costituisce un mero output di computazione, ma rappresenta il nucleo applicativo dell'intera ricerca per due ragioni fondamentali:

1. Portabilità ed Efficienza di Inferenza:

Il salvataggio dello stato dei pesi sinaptici svincola il sistema dalla necessità di rieseguire cicli di addestramento. L'architettura può essere istanziata in modalità *cold-start* su qualsiasi nodo computazionale isolato (anche in ambienti a risorse ridotte o *edge computing*), caricando i parametri appresi in tempo sub-lineare per

eseguire l'inferenza immediata su nuove ortofoto aeree.

2. Trasferimento della Conoscenza (Transfer Learning):

I pesi memorizzati ereditano le caratteristiche spettrali della morfologia mediorientale e costituiscono una solida base di partenza (*Pre-trained Weights*) per operazioni di *Fine-Tuning* su dataset di osservazione della Terra alternativi o per il monitoraggio multitemporale dell'evoluzione urbana.

Gli sviluppi futuri della ricerca si orienteranno verso l'estensione del dataset per mitigare le oscillazioni del gradiente (effetto a dente di sega) causate dall'elevata varianza inter-classe riscontrata nei mini-batch satellitari di Dubai. Sotto il profilo puramente architetturale, l'integrazione di un meccanismo di matching ungherese standard e l'introduzione di backbone nativamente operanti ad attenzione globale (come i *Swin Transformers*) consentiranno di confrontare l'efficienza di questa implementazione snella rispetto a configurazioni industriali a scala estesa, consolidando il ruolo delle *Query-Architecture* nel campo del telerilevamento spaziale.

Riferimenti bibliografici

- [1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "*Attention is all you need*", In Advances in Neural Information Processing Systems (NeurIPS), 2017.
- [2] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, and S. Zagoruyko, "*End-to-end object detection with transformers*", In European Conference on Computer Vision (ECCV), 2020.
- [3] B. Cheng, A. G. Schwing, and A. Kirillov, "*Per-pixel classification is not all you need for semantic segmentation*", In Advances in Neural Information Processing Systems (NeurIPS), 2021.
- [4] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, "*Masked-attention Mask Transformer for Universal Image Segmentation*", In IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022.
- [5] P. Gao, M. Zheng, X. Wang, J. Dai, and H. Li, "*Fast convergence of DETR with spatially modulated co-attention*", In IEEE/CVF International Conference on Computer Vision (ICCV), 2021.
- [6] W. Zhang, J. Pang, K. Chen, and C. C. Loy, "*K-Net: Towards unified image segmentation*", In Advances in Neural Information Processing Systems (NeurIPS), 2021.
- [7] X. Zhu, W. Su, L. Lu, B. Li, X. Wang, and J. Dai, "*Deformable DETR: Deformable transformers for end-to-end object detection*", In International Conference on Learning Representations (ICLR), 2021.
- [8] Dataset Dubai:
<https://www.kaggle.com/datasets/humansintheloop/segmentation-of-aerial-imagery>